

Classification par Régression Logistique

Reconnaissance des Formes (Semaine VII)

Université de Lille, France

6 mars 2013

Classification


- L'ensemble des données est partagé en quelques classes différentes,
- On a quelques exemplaires pour qui on sait les classes correctes.
- On veut classer correctement les données pour qui les classes correctes sont inconnus.

Exemple : Classification des caractères manuscrits

Données d'entrainement

5	0	4	1	9	2	1	3	1	4	3	5	3	6	1	7
2	8	6	9	4	0	9	1	1	2	4	3	2	7	3	8
6	9	0	5	6	0	7	6	1	8	7	9	3	9	8	5
3	3	3	0	7	4	9	8	0	9	4	1	4	4	6	0
4	5	6	1	0	0	1	7	1	6	3	0	2	1	1	7
9	0	2	6	7	8	3	9	0	4	6	7	4	6	8	0
7	8	3	1	5	7	1	7	1	6	3	0	2	9	3	
1	1	0	4	9	2	0	0	2	0	2	7	1	8	6	4
1	6	3	4	3	9	1	3	3	8	5	4	7	7	4	2
8	5	8	6	7	3	4	6	1	9	9	6	0	3	7	2
8	2	9	4	4	6	4	9	7	0	9	2	9	5	1	5
9	1	0	3	1	3	5	9	1	7	6	2	8	2	1	5
0	7	4	9	7	8	3	2	1	1	8	3	6	1	0	3
1	0	0	1	1	2	7	3	0	4	6	5	2	6	4	7
1	8	9	9	3	0	7	1	0	2	0	3	5	4	6	5
8	6	3	7	5	8	0	9	1	0	3	1	2	2	3	3


Ça corresponds à quel chiffre ?



Le problème de classification

le cas le plus simple

- Les données à classer sont représentées en une dimension i.e. $x \in \mathbb{R}$
- Nous avons deux classes seulement, i.e. $y \in \{0, 1\}$.



Le Problème de classification

On cherche une fonction $h : \mathbb{R} \rightarrow \{0, 1\}$ telle que pour chaque x on a

- $h(x) = 0$ si x est dans classe 0 et
- $h(x) = 1$ si x est dans classe 1

Le Problème de classification

On cherche une fonction $h : \mathbb{R} \rightarrow \{0, 1\}$ telle que pour chaque x on a

- $h(x) = 0$ si x est dans classe 0 et
- $h(x) = 1$ si x est dans classe 1



Si cette fonction existe, le problème de classification est déjà résolu.


Nous allons utiliser les données d'entraînement pour trouver h .

Une Fonction Linéaire ?

- On définit un séparateur linéaire $\theta_0 + \theta_1 x$
- On utilise les exemples disponibles pour chercher les valeurs convenables pour θ_0 et θ_1 . On prédit la classe y de la manière suivante

$$y = 1 \text{ si } \theta_0 + \theta_1 x \geq 0.5$$

$$y = 0 \text{ si } \theta_0 + \theta_1 x < 0.5$$



Question

Est-ce que cette approche va marcher ?


Le Modèle

La fonction Sigmoid où Logistique

$$g(z) := \frac{1}{1 + e^{-z}}$$

Remarque

- $0 \leq g(z) \leq 1$
- $g(z) \geq 0.5$ si $z \geq 0$
- $g(z) < 0.5$ si $z < 0$



Le Modèle

La fonction Sigmoid où Logistique


$$g(z) := \frac{1}{1 + e^{-z}}$$

Remarque

- $0 \leq g(z) \leq 1$
- $g(z) \geq 0.5$ si $z \geq 0$
- $g(z) < 0.5$ si $z < 0$

Le Modèle

$$h_{\theta}(x) := g(\theta_0 + \theta_1 x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$



Le Modèle

$$h_{\theta}(x) := \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Prédiction

$$y = 1 \text{ si } h_{\theta}(x) \geq 0.5$$

$$y = 0 \text{ si } h_{\theta}(x) < 0.5$$

Le Modèle

$$h_{\theta}(x) := \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Prédiction

$$y = 1 \text{ si } h_{\theta}(x) \geq 0.5$$

$$y = 0 \text{ si } h_{\theta}(x) < 0.5$$

L'intuition

$h_{\theta}(x)$ est l'estimation de la probabilité de $y = 1$ sachant x , i.e. $P(y = 1|x)$.
Comme on a $y = 0$ où $y = 1$, on peut dériver $P(y = 0|x)$ i.e.

$$P(y = 0|x) = 1 - P(y = 1|x) = 1 - h_{\theta}(x).$$

Le Modèle


En général les données n'ont pas qu'une seule dimension !

Chaque point \mathbf{x} est un vecteur de dimension k i.e.

$$\mathbf{x} := (x_1, x_2, \dots, x_k) \in \mathbb{R}^k.$$

Exemple

Pour $k = 2$ on a $\mathbf{x} := (x_1, x_2)$ où $x_1 \in \mathbb{R}$ est $x_2 \in \mathbb{R}$, donc $\mathbf{x} \in \mathbb{R}^2$.



Le Modèle Général

Chaque point $(x_1, x_2, \dots, x_k) \in \mathbb{R}^k$ est un vecteur de dimension k ,.

$$h_{\theta}(\mathbf{x}) := \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k)}} = \frac{1}{1 + e^{-\sum_{i=0}^k \theta_i x_i}}$$

Le Modèle Général

Chaque point $(x_1, x_2, \dots, x_k) \in \mathbb{R}^k$ est un vecteur de dimension k ,.

$$h_{\theta}(\mathbf{x}) := \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k)}} = \frac{1}{1 + e^{-\sum_{i=0}^k \theta_i x_i}}$$

$$= \frac{1}{1 + e^{-(\boldsymbol{\theta}^T \mathbf{x})}} \text{ où}$$

$$\boldsymbol{\theta} := \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_k \end{bmatrix} \text{ et } \mathbf{x} := \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_k \end{bmatrix} \text{ donc } \boldsymbol{\theta}^T \mathbf{x} = \sum_{i=0}^k \theta_i x_i.$$

Le Modèle Général

Prédiction

$y = 1$ si $h_{\theta}(\mathbf{x}) \geq 0.5$

$y = 0$ si $h_{\theta}(\mathbf{x}) < 0.5$ où

$$h_{\theta}(\mathbf{x}) := \frac{1}{1 + e^{-(\theta^T \mathbf{x})}}$$

Le Modèle Général

Prédiction


$y = 1$ si $h_{\theta}(\mathbf{x}) \geq 0.5$

$y = 0$ si $h_{\theta}(\mathbf{x}) < 0.5$ où

$$h_{\theta}(\mathbf{x}) := \frac{1}{1 + e^{-(\theta^T \mathbf{x})}}$$

$$g(z) := \frac{1}{1 + e^{-z}}$$

$g(z) \geq 0.5$ si $z \geq 0$ et $g(z) < 0.5$ si $z < 0$



Le Modèle Général


Prédiction

$$\begin{aligned} y = 1 & \text{ si } h_{\theta}(\mathbf{x}) \geq 0.5 \text{ i.e. si } \theta^T \mathbf{x} \geq 0 \\ y = 0 & \text{ si } h_{\theta}(\mathbf{x}) < 0.5 \text{ i.e. si } \theta^T \mathbf{x} < 0 \end{aligned}$$


$$h_{\theta}(\mathbf{x}) := \frac{1}{1 + e^{-(\theta^T \mathbf{x})}}$$

$$g(z) := \frac{1}{1 + e^{-z}}$$

$$g(z) \geq 0.5 \text{ si } z \geq 0 \text{ et } g(z) < 0.5 \text{ si } z < 0$$



Exemple



Prédiction

$y = 1$ si $\theta_0 + \theta_1 x_1 + \theta_2 x_2 \geq 0$

$y = 0$ si $\theta_0 + \theta_1 x_1 + \theta_2 x_2 < 0$

Remarquez que θ_0 , θ_1 et θ_2 sont inconnus. On doit les chercher !


Exemple



Supposons que $\theta := \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$ est donné donc,

$$\theta_0 = -3, \theta_1 = 1, \theta_2 = 1$$

$$X = (x_1, x_2)$$



Prédiction

$$y = 1 \text{ si } x_1 + x_2 \geq 3$$

$$y = 0 \text{ si } x_1 + x_2 < 3$$

$x_1 + x_2 = 3$ est la **frontière de décision**.

Comment trouver θ ?

Coût d'une prédiction

$$\text{coût}(h_{\theta}(\mathbf{x}), y) := \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{si } y = 0 \end{cases}$$

L'intuition

Imaginons que $y = 1$

Si $h_{\theta}(\mathbf{x}) = 1$ on a coût = 0 mais

coût $\rightarrow \infty$ lorsque $h_{\theta}(\mathbf{x}) \rightarrow 0$

Ç'est une façon de pénaliser l'algorithme pour la mauvaise prédiction !

Il faut chercher les θ qui donnent le coût le plus petit possible.

Régression Logistique : Comment trouver θ ?

Coût d'une prédiction

$$\begin{aligned}\text{coût}(h_{\theta}(\mathbf{x}), y) &:= \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{si } y = 0 \end{cases} \\ &= -y \log(h_{\theta}(\mathbf{x})) - (1 - y) \log(1 - h_{\theta}(\mathbf{x})) \text{ pourquoi ?}\end{aligned}$$

Régression Logistique : Comment trouver θ ?

Coût d'une prédiction

$$\begin{aligned}\text{coût}(h_{\theta}(\mathbf{x}), y) &:= \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{si } y = 0 \end{cases} \\ &= -y \log(h_{\theta}(\mathbf{x})) - (1 - y) \log(1 - h_{\theta}(\mathbf{x})) \text{ pourquoi ?}\end{aligned}$$

La fonction de coût $J(\theta)$

On a m exemplaires d'entraînement $\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)}\}$. Soit $y^{(i)}$ la classe de $\mathbf{x}^{(i)}$, $i = 1..m$.

On définit la fonction de coût par

$$J(\theta) := -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

Comment trouver θ ?

On cherche les paramètres qui donnent le coût le plus petit possible

$$\theta^* := \min_{\theta} J(\theta) \text{ où}$$

$$J(\theta) := -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

→ minimiser la fonction de coût $J(\theta)$ et
utiliser le θ qui correspond à $J(\theta)$ minimum

La minimisation de $J(\theta)$ est possible pas les méthodes de la théorie d'optimisation, mais cela dépasse le cadre de ce cours

→ Nous allons utiliser les fonctions d'optimisations existantes en scilab.

Comment trouver θ ?

On cherche les paramètres qui donnent le coût le plus petit possible

$$\theta^* := \min_{\theta} J(\theta) \text{ où}$$

$$J(\theta) := -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

→ minimiser la fonction de coût $J(\theta)$ et
utiliser le θ qui correspond à $J(\theta)$ de minimum

L'algorithme

Entraînement

Utiliser **les données d'entraînement**, i.e. **les exemplaires**

$\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)}\}$ et **leur labels** $\{y^{(1)}, y^{(2)}, \dots, y^{(m)}\}$ pour trouver le vecteur θ . Donc,

$m = \text{nb d'entraînement}$

$\theta^* := \min_{\theta} J(\theta)$ où

une image

$$J(\theta) := -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

Prédiction de la classe d'un nouvel exemple

Pour chaque nouveau \mathbf{x} $h_{\theta}(\mathbf{x}) := \frac{1}{1+e^{\theta^T \mathbf{x}}}$ classifier le de la manière suivante,

$$y = 1 \text{ si } h_{\theta}(\mathbf{x}) \geq 0.5$$



$$y = 0 \text{ si } h_{\theta}(\mathbf{x}) < 0.5$$

L'algorithme Multi-Classes

Pour l'instant cette approche marche que pour le cas de deux classe $y \in \{0, 1\}$ seulement.

Question

Comment peut on le généraliser pour le cas de plusieurs classes ?



L'algorithme Multi-Classes

Supposons que l'on a $l > 2$ classes, i.e. $y \in \{1, 2, \dots, l\}$. On peut créer un classifieur de la manière suivante.

- 1 **Entraîner** un classifieur de régression logistique $h_{\theta}^{(i)}(\mathbf{x})$ pour chaque classe $i = 1, 2, \dots, l$.

Rappel : $h_{\theta}^{(i)}(\mathbf{x})$ estime $P(y = i|\mathbf{x})$, $i = 1, 2, \dots, l$

- 2 Pour **prédire** la classe d'un nouveau \mathbf{x} , choisir $y \in \{1, 2, \dots, l\}$ tel que

$$y = \max_{i=1..l} h_{\theta}^{(i)}(\mathbf{x})$$

Ça veut dire que l'on suit la décision du classifieur plus confiants.

L'algorithme Multi-Classes : Exemple

