

Apprentissage supervisé (suite) : Réseaux de Neurones Apprentissage non-supervisé : Clustering

Reconnaissance des Formes (Semaine VIII)

Université de Lille, France

13 mars 2013


Rappel

Apprentissage Supervisé

L'objectif est de trouver la structure/forme dans les données, en utilisant quelques exemplaires pour lesquels la solution est connue.

Exemple : Classification

- L'ensemble des données est partagé en quelques classes différentes,
- On a quelques exemplaires pour qui on sait les classes correctes.
- On veut classifier correctement les données pour qui les classes correctes sont inconnus.



Algorithmes d'apprentissage supervisé déjà étudiés en cours

- ① k -Nearest Neighbors ou k plus proches voisins

Approche : Classifier chaque point x par la vote à la majorité de ses k voisins les plus proches

Algorithmes d'apprentissage supervisé déjà étudiés en cours

- ① k -Nearest Neighbors ou k plus proches voisins

Approche : Classifier chaque point x par la vote à la majorité de ses k voisins les plus proches

- ② Naïve Bayes : Un modèle probabiliste qui consiste à choisir la classe la plus probable pour chaque point x
 - **Règle de décision :** Maximum a Posteriori (MAP)
 - **l'hypothèse principale :** Indépendance Conditionnelle

Algorithmes d'apprentissage supervisé déjà étudiés en cours

- ① *k*-Nearest Neighbors ou *k* plus proches voisins

Approche : Classifier chaque point \mathbf{x} par la vote à la majorité de ses *k* voisins les plus proches

- ② Naïve Bayes : Un modèle probabiliste qui consiste à choisir la classe la plus probable pour chaque point \mathbf{x}

- **Règle de décision** : Maximum a Posteriori (MAP)
- **l'hypothèse principale** : Indépendance Conditionnelle

- ③ Régression Logistique (pour classification en deux classes 0 ou 1)


Approche : Pour chaque \mathbf{x} calculer $h_{\theta}(\mathbf{x}) := \frac{1}{1+e^{-\theta^T \mathbf{x}}}$

- **Prédiction** : Classifier \mathbf{x} dans la classe 1 si $h_{\theta}(\mathbf{x}) \geq 0.5$ et dans la classe 0 si $h_{\theta}(\mathbf{x}) < 0.5$
- **Trouver θ** : Utiliser les exemplaires pour trouver le θ qui minimise une fonction de coût $J(\theta)$

Réseaux de Neurones :

Un autre Modèle pour apprentissage supervisé


- Algorithmes qui essaient d'imiter le cerveaux en apprentissage




- Utilisés dans les années 80 et 90, mais abandonnés vers la fin des années 90 !
 - peut-être car ils demandent beaucoup de capacité de calculs
- Retour en grâce : énormément utilisées pour des nombreuses applications !
- Il nous permet de trouver les frontières de décision non-linéaires

Modéliser un Neurone


Neurone est modéliser comme un unit logistique



où $h_{\theta}(\mathbf{x}) := g(\boldsymbol{\theta}^T \mathbf{x})$ et $g(z) := \frac{1}{1+e^{-z}}$ est la fonction d'**activation** sigmoid ou logistique :



Modéliser le Réseaux de Neurones



(les couches intermédiaires s'appellent les couches cachés)

Paramètres

- $a_i^{(j)}$: La fonction d'activation i à couche j
- Θ : Une **matrice** des poids qui contrôle les activations entre couches j et $j + 1$

Apprentissage (par l'algorithme BackPropagation)

De manière similaire à régression logistique l'on utilise les données d'entraînement pour minimiser une fonction de coût $J(\Theta)$

Réseaux de Neurones en Action

Demo : par Yann Lecun

Apprentissage Non-Supervisé

Objectif


Trouver une structure/forme dans les données sans exemples ou l'ensemble d'entraînement

Exemple : Clustering → Classification sans données d'entraînement

Classification


entrée :

$$\{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$$




Clustering


entrée : $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$




L'algorithme k-Means




L'algorithme k-Means




L'algorithme k-Means




L'algorithme k-Means




L'algorithme k-Means




L'algorithme k-Means



L'algorithme k-Means



L'algorithme k-Means



L'algorithme k-Means

Entrées :

K := nombres des clusters (groups)

Données à grouper : $\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)}\}$

① Initialiser aléatoirement K centre du cluster $\mu_1, \mu_2, \dots, \mu_K$

② Répéter

① **[i.] Attribuer chaque point $\mathbf{x}^{(i)}$ à un des K clusters :**

for $i = 1..m$

$c^{(i)} \leftarrow$ l'indice (entre $1..K$) du centre le plus proche de $\mathbf{x}^{(i)}$

endfor

② **[ii.] Mettre à jour les centres :**

for $k = 1..K$

$\mu_k \leftarrow$ la moyenne des points attribués à cluster k

endfor

L'algorithme k-Means

Remarque

- Normalement l'initialisation des centres est fait aléatoirement
- L'algorithme est arrêté à partir du moment où les centres ne changent plus

Application pour Traitement d'image

Compression d'image par K-means

- Dans le format de codage des couleurs RGB (Red, Green, Blue), chaque pixel est représenté par trois entiers entre 0..255, qui spécifient l'intensité des couleurs Rouge, Vert et Bleu.
- Normalement, chaque image est composé de nombreuses couleurs
 - Une façon de représenter un image de manier efficace est de réduire le nombre des couleurs dans l'image

Original



Compressé (16 couleurs)



Compression d'image par K-means

Approche

- Traiter chaque pixel comme un vecteur de donnée de dimension trois, i.e. chaque pixel est $\mathbf{x} \in \mathbb{R}^3$
- Utiliser K-means pour grouper les pixels en K clusters de couleurs
- Remplacer chaque pixel dans l'image original par le centre de son cluster

Remarque : On utilise la distance Euclidienne.

Demo !